

بسمه تعالی



دانشکده مهندسی کامپیوتر

پاییز ۱۴۰۰

یادگیری عمیق

نام استاد: دکتر محمدی

تمرین اول

آرمان حیدری

شماره دانشجویی: ۹۷۵۲۱۲۵۲

۱. پاسخ سوال اول

- **AI winter**: در تاریخ هوش مصنوعی، بازه‌های زمانی وجود دارد که سرمایه‌گذاری و علائق مردم نسبت به هوش مصنوعی کاهش یافته بود. این اطلاق را به آن دوره‌ها می‌گوییم.
- **Backpropagation**: الگوریتمی از یادگیری **supervised** است که در شبکه‌های عصبی و با استفاده از **gradient decent** کار می‌کند. هدف از این الگوریتم اعمال تغییرات روی وزن‌های لایه‌های مختلف شبکه عصبی بر اساس گرادیان خطای خروجی نهایی شبکه می‌باشد.
- **Objective function**: تابعی که رابطه آن را می‌خواهیم حداقل یا حداکثر کنیم تا با استفاده از آن سود را زیاد و ضرر را تا جای ممکن کاهش دهیم. البته معمولاً محدودیت‌های مختلفی روی متغیرها وجود دارد و در روابط باید لحاظ شوند.
- **Kernel methods**: دسته‌ای از الگوریتم‌های **classification** هستند که در **SVM** بسیار کاربرد دارند. هدف از این الگوریتم‌ها این است که داده‌ها را به بعدهای بالاتر ببریم تا **classification** ساده‌تر شود. اساس آن‌ها این است که در فضای نمونه‌ای جدید، صرفاً محاسبه‌ی فاصله‌ی بین نقاط کفایت می‌کند و تخمین زدن دقیق مقدار نیاز نیست.
- **4D tensors vs. 4-dimensional vector**: این دو را نباید باهم اشتباه بگیریم. بردارهای ۴ بعدی، فقط یک محور دارند که خود این محور ۴ بعد دارد. در حالی که **tensor** ۴ بعدی، ۴ محور دارد و هر کدام از این محورها می‌توانند چندین بعد داشته باشند.
- **Element-wise product vs. Tensor product**: این دو را نباید باهم اشتباه بگیریم. ضرب **element-wise** یا **hadamard**، همان ضرب ماتریس هاست که در واقع حاصل ضرب دو ماتریس به اندازه $m \times n$ و $n \times h$ ، یک ماتریس $m \times h$ می‌شود. نماد آن در کتابخانه‌های مختلف **numpy** و **keras** و **Theano** و **tensorflow**، "*" است. اما ضرب **tensor**، که در ریاضی نمادش "⊗" است و در **numpy** آن را با **"dot"** می‌شناسیم، خروجی عدد می‌دهد و المان‌های دو بردار را ضرب می‌کند و جمع آن‌ها را برمی‌گرداند.

۲. پاسخ سوال دوم

اگر هر کدام از ستون های بردار x را به ترتیب x_1 ، x_2 ، x_3 بنامیم، داده های زیر را طبق ورودی سوال خواهیم داشت:

	Mean(x1)	Variance(x1)	Mean(x2)	Variance(x2)	Mean(x3)	Variance(x3)
Spam	0.17	0.1667	0.83	0.1667	0.67	0.403
Nspam	1	0	0.25	0.25	0.25	0.25

حال می توانیم طبق فرمول gaussian naïve bayes، احتمالات زیر را برای $X1 = [1 \ 1 \ 0]$ محاسبه کنیم:

$$p(x = v \mid C_k) = \frac{1}{\sqrt{2\pi\sigma_k^2}} e^{-\frac{(v-\mu_k)^2}{2\sigma_k^2}}$$

$$P(x_1 \mid \text{spam}) = 0.124, \quad P(x_2 \mid \text{spam}) = 0.902, \quad P(x_3 \mid \text{spam}) = 0.36, \quad P(\text{spam}) = 0.6$$

$$P(x_1 \mid \text{Nspam}) = 1, \quad P(x_2 \mid \text{Nspam}) = 0.26, \quad P(x_3 \mid \text{Nspam}) = 0.706, \quad P(\text{Nspam}) = 0.4$$

سپس می توانیم طبق فرمول naïve bayes برای ورودی های مختلف احتمال اسپم بودن یا نبودن را بررسی کنیم: (/ علامت تقسیم است)

$$P(X1 \text{ is spam}) = P(x_1 \mid \text{spam}) * P(x_2 \mid \text{spam}) * P(x_3 \mid \text{spam}) * P(\text{spam}) / \text{evidence} = 0.124 * 0.902 * 0.36 * 0.6 = 0.024$$

$$P(X1 \text{ is not spam}) = P(x_1 \mid \text{Nspam}) * P(x_2 \mid \text{Nspam}) * P(x_3 \mid \text{Nspam}) * P(\text{Nspam}) / \text{evidence} = 1 * 0.26 * 0.706 * 0.4 = 0.073$$

پس پیشبینی میکنیم که $X1$ ، اسپم نیست.

و به طور مشابه برای $X2 = [1 \ 1 \ 1]$ خواهیم داشت:

$$P(X_2 \text{ is spam}) = 0.124 * 0.902 * 0.546 * 0.6 = 0.037$$

$$P(X_2 \text{ is not spam}) = 1 * 0.26 * 0.26 * 0.4 = 0.027$$

پس پیشبینی میکنیم که X_2 اسپم است.

۳. پاسخ سوال سوم

پس از دریافت dataset مطابق توضیحات صورت سوال، به این ترتیب موارد خواسته شده را به دست می آوریم:

1. data type of sets:

```
[14] print("x_train data type: ", x_train.dtype)
      print("y_train data type: ", y_train.dtype)
      print("x_test data type: ", x_test.dtype)
      print("x_test data type: ", y_test.dtype)
```

```
x_train data type:  uint8
y_train data type:  uint8
x_test data type:   uint8
x_test data type:   uint8
```

که این خروجی نشان دهنده این است که تمامی دیتاهای موجود در این ۴ آرایه از نوع uint8 هستند. (چون درواقع rgb پیکسل های مختلف هستند و اعدادی ۸ بیتی بین ۰ تا ۲۵۵ هستند).

2. rank of sets:

```
[19] print("x_train rank: ", x_train.ndim)
      print("y_train rank: ", y_train.ndim)
      print("x_test rank: ", x_test.ndim)
      print("x_test rank: ", y_test.ndim)
```

```
x_train rank:  4
y_train rank:  2
x_test rank:   4
x_test rank:   2
```

این خروجی نشان دهنده تعداد ابعاد هر کدام از این آرایه ها می باشد. یعنی x_train و x_test آرایه های ۴ مولفه ای و y_train و y_test آرایه های ۲ مولفه ای هستند. فعلا نمی توانیم حدس خوبی از این ابعاد بزنیم اما در بخش بعدی همین سوال متوجه می شویم.

3. shape of sets:

```
print("x_train shape:", np.shape(x_train))  
print("y_train shape:", np.shape(y_train))  
print("x_test shape:", np.shape(x_test))  
print("y_test shape:", np.shape(y_test))
```

```
x_train shape: (50000, 32, 32, 3)  
y_train shape: (50000, 1)  
x_test shape: (10000, 32, 32, 3)  
y_test shape: (10000, 1)
```

این خروجی ابعاد دقیق هر کدام از این آرایه‌ها را نمایش می‌دهد. یعنی می‌فهمیم که در `x_train`، ۵۰۰۰۰ عکس وجود دارد که ابعاد 32×32 دارند و سه مولفه رنگی آن‌ها را در اختیار داریم. `x_test` هم مشابه همان است و فقط تعداد عکس‌ها ۱۰۰۰۰ تا است. همچنین `y_train`، به ازای هر کدام از آن ۵۰۰۰۰ عکس یک `label` دارد و `y_test` هم به همین صورت برای ۱۰۰۰۰ عکس موجود در داده‌های تست.

*** فایل Q3.ipynb پاسخ این بخش می‌باشد و ضمیمه شده است.

۴. پاسخ سوال چهارم

پیاده سازی این سوال در فایل Q4.ipynb انجام شده و پیوست شده است. همچنین در لینک زیر قابل مشاهده و اجراست:

https://colab.research.google.com/drive/1XxfrB7pDcnkh0i8EI-qNcOjQHOhp_VMm?usp=sharing

همانطور که می بینید به دقت ۹۶ درصد با الگوریتم navie bayes می‌رسیم.